RELAZIONE TECNICA · PROGETTO FINALE LLM & AGENTIC AI

Casa & Regali — assistente clienti

Versione 2 (v2) · un agente, un passaggio di tool, un secondo passo LLM per la risposta

Abstract. Il progetto realizza un assistente clienti in italiano per un e-commerce fittizio di complementi d'arredo. L'LLM sceglie uno dei sette tool e scrive la risposta; un secondo passo LLM, senza tool, racconta l'esito. Le regole di dominio — finestra di reso, esclusioni, soglia di rimborso, privacy — sono codice deterministico. Il rimborso viene solo *proposto*: entra nel ledger unicamente dopo l'approvazione di un operatore. La v2 è la versione ottimizzata di un progetto esteso con supervisore, tre agenti, reflection e Chroma, e misura il risultato su 31 scenari con un modello locale da 1,7B.

31/31	100,0%	60	3,72 s
scenari superati	tool hit rate	test automatici	latenza media

1. Contesto e obiettivo

Un assistente clienti non è un problema di conversazione: è un problema di responsabilità. La risposta può essere scritta dall'LLM, ma un reso fuori finestra, un ordine di un altro cliente o un rimborso già eseguito non sono opinioni: sono fatti e regole. Se il modello sbaglia, l'errore non deve diventare una scrittura irreversibile.

Ho scelto un dominio chiuso: **10 documenti** di policy, **200 ordini** sintetici e **50 clienti**. Le richieste sono eterogenee — «quanto costa la spedizione?», «dov'è ORD-1001?», «posso restituire una tazza personalizzata?», «voglio il rimborso di ORD-1005» — ma finiscono tutte nello stesso punto: una risposta in italiano che deve usare i dati giusti, applicare le regole giuste e non superare i limiti del proprio ruolo.

L'obiettivo non è accumulare pattern. È costruire un turno che risponda con fonti verificabili, usi solo gli ordini del cliente della sessione, applichi la policy in modo deterministico e chieda l'approvazione di un umano prima di un'azione sensibile. Il criterio di successo è misurabile: tool corretto, risposta corretta, nessun accesso a ordini altrui, nessun rimborso senza approvazione, nessun effetto collaterale indesiderato.

- **Rispondere** in italiano, citando `[S1]`, `[S2]` quando la risposta viene dal corpus.
- **Usare** solo gli ordini del profilo della sessione, mai un cliente scelto dal modello.
- **Applicare** finestra di reso, esclusioni e soglie con codice deterministico.
- **Chiedere** l'approvazione umana prima di scrivere un rimborso.

2. La tesi: due decisioni all'LLM, i vincoli al codice

La domanda di progetto è stata: **quale parte del sistema ha davvero bisogno dell'LLM?** La risposta è duplice. L'LLM serve per scegliere il tool e per scrivere una risposta in linguaggio naturale. Tutto il resto — idoneità al reso, soglie di rimborso, privacy, approvazione, scrittura del ledger — è codice deterministico e verificabile.

Ho scelto di separare la *scelta* dalla *narrazione*: il nodo `agent` decide, il nodo `tools` esegue, il nodo `respond` scrive senza poter avviare altre azioni. In questo modo l'LLM prende due decisioni osservabili, ma non può concatenare azioni né aggirare un vincolo di dominio.

> **La scelta di progetto**
>
> Non c'è una modalità deterministica che sostituisca il modello quando sbaglia: gli errori restano visibili nella valutazione. È una scelta più onesta e più leggibile di un fallback che maschera il comportamento reale.

2.1 Cosa fa il modello, cosa fa il codice

Compito	Responsabile
Scegliere il tool e i suoi argomenti	LLM
Scrivere la risposta al cliente	LLM
Applicare finestra resi, esclusioni e soglie	`policy.py`
Garantire il cliente della sessione	`ToolRuntime` + `tools.py`
Sospendere il turno per l'approvazione	`interrupt()`
Scrivere il rimborso solo se approvato	`audit.py` (ledger)
Registrare turni, accessi negati e ticket	`audit.py`

Policy-as-code. La fonte di verità è `policy.py`: **30 giorni** di reso, categorie escluse (personalizzati, igiene, digitali, fine serie), soglia di escalation di **500 EUR**, prima risposta di un ticket entro **24 ore**, calcolo del rimborso e controllo duplicati. I documenti *spiegano* la policy, i tool la *applicano*; un test confronta i numeri dei documenti con le costanti del codice.

Privacy. Il `customer_id` arriva dallo stato del grafo tramite `ToolRuntime`: il modello non sceglie di quale cliente parlare. Un ordine altrui restituisce lo stesso messaggio di un ordine inesistente, e l'accesso negato finisce nell'audit. I dati del profilo non vengono passati al modello: i tool restituiscono solo i campi dell'ordine necessari.

3. Architettura e un turno

Il grafo ha quattro nodi: **agent** sceglie un tool o risponde; **tools** esegue il tool con il `ToolRuntime` della sessione; **respond** è un secondo passo LLM senza tool che scrive la risposta; **finalize** salva risposta, fonti e tool usati e scrive il turno nell'audit. Se non serve un tool, il percorso è `agent` → `finalize`.

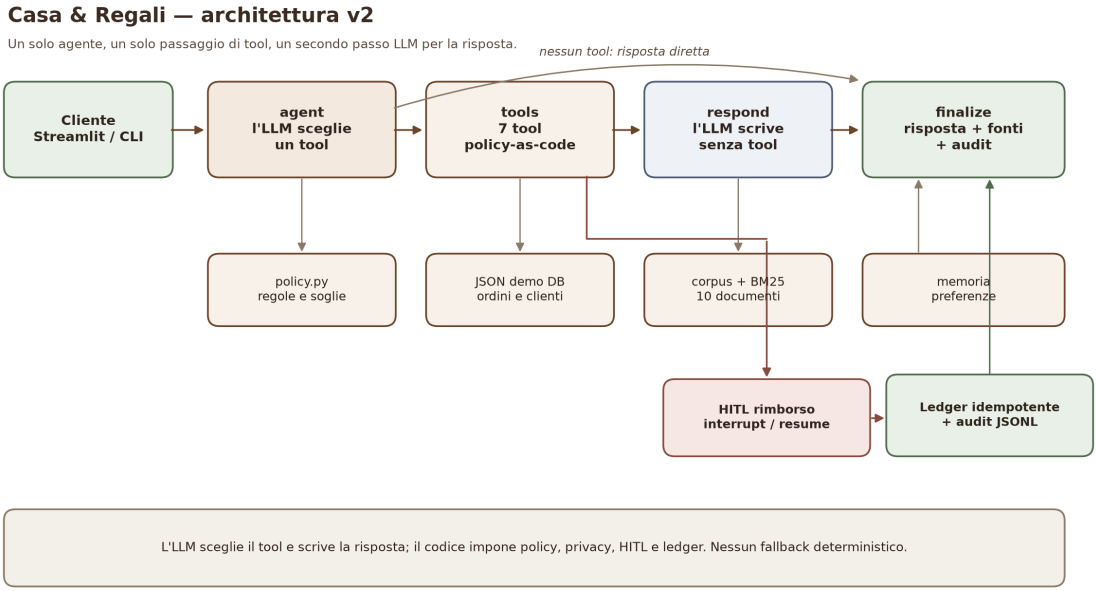


Figura 1 — Flusso agent → tools → respond → finalize. La freccia superiore è il percorso senza tool; il ramo rosso è il rimborso con HITL e ledger.

Ho scelto un solo passaggio di tool per turno. Il ciclo ReAct completo (`agent` → `tools` → `agent` → …) con modelli da 1-3B tende a ripetere lo stesso tool o a concatenarne altri dopo un esito già definitivo. Separare scelta e narrazione riduce latenza e catene incontrollate.

Un turno completo. «Voglio il rimborso di ORD-1001»: `agent` chiama `proponi_rimborso("ORD-1001")`; il tool verifica il cliente, applica la policy e calcola **89,70 EUR**. `interrupt()` sospende il turno con una proposta a livello *operatore*; la UI riprende con `Command(resume=...)` e il ledger rivalida cliente, importo e duplicati prima di scrivere. `respond` racconta l'esito, `finalize` registra il turno; se l'operatore rifiuta, non viene scritto nulla.

4. Funzionalità e perché

Funzionalità	Obiettivo	Perché questa scelta	Evidenza
RAG BM25 su 10 documenti, chunk 650/50, top 3	Risposte informative con fonti verificabili	Corpus breve e lessico stabile: niente embedding né indice persistente; le fonti sono deterministiche	Source hit 100% sui 9 scenari informativi
Memoria breve con `InMemorySaver`	Mantenere il filo della conversazione	Checkpointer LangGraph e un `thread_id` per sessione; lo stato non serve al di fuori del thread	Test di memoria tra turni
Memoria lunga `PreferenceMemory`	Ricordare solo ciò che il cliente chiede	Nessun profilo dedotto: salvataggio solo su «ricorda», PII rimosse, duplicati ignorati	Test su PII e duplicati
HITL dentro `proponi_rimborso`	Nessun rimborso senza un umano	`interrupt()` lega proposta e approvazione; il ledger rivalida cliente, importo e duplicati	HITL 100%, rimborso pulito 100%
Audit JSONL e ledger idempotente	Rendere ogni azione verificabile	Un evento per turno, accesso negato, rimborso e ticket; scrittura atomica e controllo dei duplicati	Test di ledger e idempotenza
UI Streamlit e CLI	Demo e ispezione dello stesso sistema	Stesso grafo, stesso ledger e stessi dati: cambia solo il modo di interagire	13 scenari demo nella UI; comandi CLI

Perché un tool e non solo prompting. Il modello non conosce gli ordini del cliente, non può calcolare un rimborso e non può verificare una finestra di reso. Un prompt può descrivere la regola, ma non applicarla né impedire una scrittura. I sette tool portano nel turno dati reali e controlli deterministici: è il motivo per cui il progetto non si limita a chiedere al modello di «comportarsi bene».

5. Scelte e alternative scartate

Scelta	Alternativa scartata	Perché	Conseguenza
Un solo agente	Supervisore con agenti specialistici	Sette tool e un dominio: la divisione in specialisti moltiplica le chiamate senza aggiungere capacità	31/31, 0,94 tool per turno
Un passaggio di tool, poi `respond`	Ciclo ReAct completo	Con modelli piccoli il ciclo tende a ripetere il tool o a concatenarne altri dopo un esito definitivo	Nessun tool dopo il rimborso
BM25	Chroma con embedding	Dieci documenti brevi: BM25 è deterministico, non richiede indice né modello di embedding	Source hit 100%
Policy-as-code	Regole nel system prompt	Il prompt può essere ignorato o attaccato con prompt injection; il codice no	Prompt injection superata
HITL nel tool	Nodo di approvazione separato	Proposta e approvazione restano nello stesso punto; un nodo separato lascerebbe altri percorsi di scrittura	Rimborso pulito 100%
Eval custom e audit JSONL	LangSmith	La suite è piccola e il progetto resta riproducibile senza account esterni; il JSONL copre turni, privacy e rimborsi	31 scenari e failure gallery

Prompting. Il system prompt usa ruolo e vincoli espliciti, few-shot per la scelta del tool e per la risposta diretta, e output strutturato: lo schema degli argomenti è generato da LangChain a partire dalle annotazioni dei tool, quindi il modello non può inventare campi o formati. Il prompt di scelta è breve — con modelli da 1-3B poche regole chiare sono più affidabili di un elenco lungo — mentre il prompt finale riceve solo richiesta ed esiti, vieta calcoli e dati inventati e non può avviare altre azioni. Il prompt finale cambia per tool e chiede un blocco `<risposta>`: il codice estrae solo quel blocco, così il ragionamento non arriva al cliente.

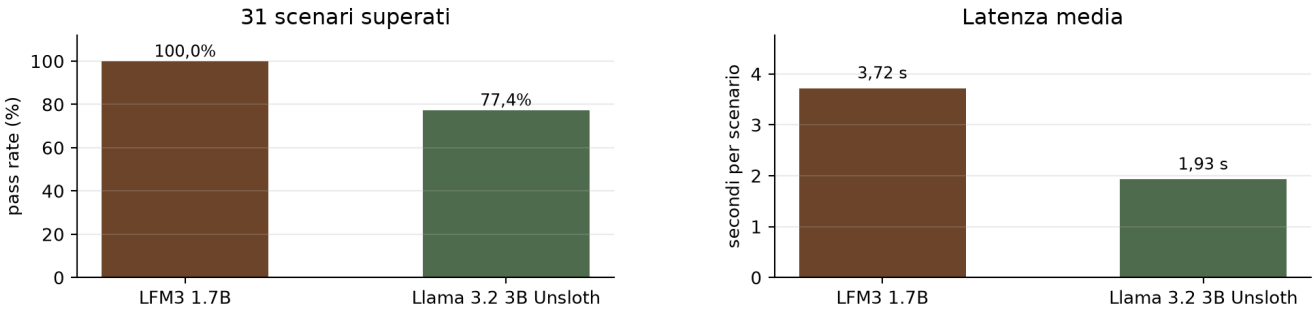
Perché non multi-agente, reflection o LangSmith. Non li ho aggiunti perché il caso d'uso non li richiede: un dominio, sette tool, un turno singolo. Supervisore e reflection aggiungerebbero passaggi e latenza senza migliorare la scelta; LangSmith sarebbe un account esterno per 31 scenari già coperti da JSON e failure gallery.

Un fallimento concreto. Nella run Unsloth, `info_personalizzato` chiama `verifica_reso` invece di `cerca_policy`; `memoria_implicita` salva una preferenza non richiesta. La failure gallery conserva questi errori.

6. Valutazione

La suite contiene **31 scenari**: 9 informazioni, 3 ordini, 6 resi, 6 rimborsi, 3 sicurezza (privacy, ordine inesistente, prompt injection), 2 escalation e 2 memoria. Ogni scenario verifica, dove previsto, tool attesi e vietati, contenuto, fonti, interrupt HITL, scritture e assenza di effetti collaterali. I rimborsi usano dati temporanei, senza toccare la demo.

Profilo	Superati	Pass rate	Tool hit	Fonti	HITL	Sicurezza	Latenza
LFM3-1.7B Q4_K_M	31/31	100,0%	100,0%	100,0%	100,0%	100,0%	3,72 s
Llama 3.2 3B Unsloth	24/31	77,4%	96,6%	88,9%	100,0%	66,7%	1,93 s



LFM3 è più lento ma più affidabile: **31/31** con **0,94 tool per turno** e 3,72 s medi. Llama (Unsloth) è più veloce (1,93 s) ma si ferma a 24/31: sbaglia tool, fonti e sicurezza (66,7% contro 100,0%); i 7 fallimenti si concentrano su resi, memoria e sicurezza. Il modello più piccolo non è un dettaglio: è il vincolo che rende necessari i confini di codice.

Reasoning. Con LFM3 il reasoning attivo (variabile vuota) ha dato la migliore scelta dei tool. La risposta finale lo disattiva sempre: con la tabella dei 10 ordini il secondo passo consumava **7.058 token** e restituiva contenuto vuoto. Con `LM_STUDIO_REASONING_EFFORT=none` su tutto il grafo una run precedente si è fermata a **27/31**. **Gemini.** Il backend cloud è presente, ma non c'è una run completa per esaurimento della quota: non riporto una metrica che non ho misurato.

Metodo. La valutazione misura il sistema così com'è: se il modello sceglie il tool sbagliato o inventa un numero, lo scenario fallisce. Non c'è una correzione a posteriori che nasconda l'errore; la failure gallery conserva risposta, tool e controlli falliti. La suite automatica usa un modello scriptato (`ScriptedModel`) e dati isolati: **60 test** senza LM Studio né rete, a copertura di grafo, HITL, privacy, memoria, policy, corpus, ledger e scenari.

7. Limiti e conclusione

- **Modelli piccoli.** LFM3 1,7B e Llama 3.2 3B (Unsloth) possono sbagliare la scelta del tool o riformulare i numeri; la valutazione misura questi errori e non li corregge con un fallback.
- **Un tool per turno.** Una richiesta che ne richiede due viene gestita al turno successivo: è una scelta deliberata, non un limite tecnico del grafo.
- **BM25.** Adatto a dieci documenti brevi; su un corpus più grande servirebbe ricerca semantica o ibrida.
- **Memoria di sessione.** `InMemorySaver` perde lo stato al riavvio; le preferenze a lungo termine restano su file.
- **Demo a processo singolo.** Ledger e memoria usano lock di processo e file JSON, adatti alla demo ma non a un deployment multi-istanza.

La v2 mantiene i vincoli di dominio e toglie i pattern che, con un modello da 1-3B, non ripagavano la complessità. Il grafo è piccolo abbastanza da essere letto in un minuto, ma il comportamento non è simulato: l'LLM sceglie davvero il tool, scrive davvero la risposta e sbaglia quando il modello sbaglia. La differenza è che gli errori sono visibili nella valutazione, non nascosti da un fallback.

Il 31/31 di LFM3 non è una garanzia di produzione: è la misura di un prototipo su 31 scenari controllati, con un modello locale e dati sintetici. Llama 3.2 3B (Unsloth) mostra che il margine di errore esiste e dipende dal modello. Il secondo passo LLM separato riduce però il perimetro degli errori: la risposta può essere imprecisa, ma non può avviare un rimborso o cambiare cliente.